Data Frames

Mario A. Morales Rivera
mamorales@correo.unicordoba.edu.co
Universidad de Córdoba



Tabla de contenidos I

1. Data Frames conceptos básicos
2. DataFrames: creación
3. Inspección rápida y estructura
4. Nombres de filas y columnas
5. Adición de columnas
6. Indexado



Data Frames conceptos básicos



Data Frames en R

Nota

Un **Data Frame** en R es una estructura de datos bidimensional y tabular, diseñada específicamente para el análisis estadístico. Técnicamente, es una lista de vectores (o factores) que comparten exactamente la misma longitud.



Data frames: características

- Cada **columna** representa una variable y cada **fila** representa una observación o caso.
- A diferencia de las matrices en R (que admiten un solo tipo de dato), los data frames son heterogéneos: permiten almacenar diferentes tipos de datos (numéricos, caracteres, lógicos, factores) en distintas columnas.
- Es el objeto estándar para la manipulación de datos y el ajuste de modelos estadísticos en R.



DataFrames: creación



Creación de DataFrames

Una forma de crear `DataFrames` en R es mediante la función `data.frame`, como se muestra a continuación

```
set.seed(1234)
# 10 datos simulados de una variable aleatoria binmial con n=20 y p=0.4
x<-rbinom(10,20,0.4)
# vector de caracteres aleatorios
y<-sample(c("F","M"),10,replace=TRUE)
# vector logico
z<-runif(10)>0.5
```



A continuación creamos un DataFrame con estos tres vectores

```
datos=data.frame(x,y,z)
datos
```

```
    x y     z
1   5 M FALSE
2   9 M FALSE
3   9 M FALSE
4   9 F FALSE
5  10 M FALSE
6   9 M  TRUE
7   3 M  TRUE
8   6 F  TRUE
9   9 M  TRUE
10  8 M FALSE
```



Inspección rápida y estructura



Estructura del data

Para verificar la estructura interna, los tipos de datos de cada columna y la longitud del data frame, usamos `str(datos)`

```
str(datos)
```

```
'data.frame':   10 obs. of  3 variables:
 $ x: int  5 9 9 9 10 9 3 6 9 8
 $ y: chr  "M" "M" "M" "F" ...
 $ z: logi  FALSE FALSE FALSE FALSE FALSE TRUE ...
```



Resumen básico

Para obtener un resumen estadístico básico (mínimo, máximo, cuartiles, media) para variables numéricas, y conteos para factores/caracteres.

```
summary(datos)
```

```
       x                y                  z          
 Min.   : 3.0   Length:10          Mode :logical  
 1st Qu.: 6.5   Class :character   FALSE:6  
 Median : 9.0   Mode  :character   TRUE :4  
 Mean   : 7.7                                
 3rd Qu.: 9.0                                
 Max.   :10.0
```



Dimensiones del data

Para saber rápidamente las dimensiones (filas y columnas) del data frame usamos `dim(datos)`

```
dim(datos)
```

```
[1] 10  3
```



Las funciones `head()` y `tail()`

Para explorar las primeras o últimas filas de un data frame grande sin saturar la consola.

```
head(datos,3)
```

```
  x y     z
1 5 M FALSE
2 9 M FALSE
3 9 M FALSE
```

```
tail(datos)
```

```
    x y     z
5  10 M FALSE
6   9 M  TRUE
7   3 M  TRUE
8   6 F  TRUE
9   9 M  TRUE
10  8 M FALSE
```



¿Es un data?

Para saber si efectivamente un objeto en R es un `DataFrame` podemos ejecutar los siguientes comandos

```
class(datos)
```

```
[1] "data.frame"
```

```
is.data.frame(datos)
```

```
[1] TRUE
```

```
mode(datos)
```

```
[1] "list"
```



Nombres de filas y columnas



Nombres de columnas

Observe que los nombres de columna se toman de los nombres de los vectores usados para crear el data, si queremos otros nombres de columnas procedemos de la siguiente forma

```
datos=data.frame(Cx=x,Cy=y,Cz=z)
datos
```

```
   Cx Cy    Cz
1   5  M FALSE
2   9  M FALSE
3   9  M FALSE
4   9  F FALSE
5  10  M FALSE
6   9  M  TRUE
7   3  M  TRUE
8   6  F  TRUE
9   9  M  TRUE
10  8  M FALSE
```



Nombres de filas

También podemos colocar nombres de filas al data al momento de crearla, de la siguiente forma

```
datos=data.frame(Cx=x,Cy=y,Cz=z,row.names=month.abb[1:10])
datos
```

```
    Cx Cy    Cz
Jan  5  M FALSE
Feb  9  M FALSE
Mar  9  M FALSE
Apr  9  F FALSE
May 10  M FALSE
Jun  9  M  TRUE
Jul  3  M  TRUE
Aug  6  F  TRUE
Sep  9  M  TRUE
Oct  8  M FALSE
```



Nombres de filas II

Cuando uno de los vectores con que creamos el data tiene nombres para sus elementos, la función `data.frame` toma estos nombres como nombres de fila del data creado.

```
names(y)=LETTERS[1:10]
datos=data.frame(Cx=x,Cy=y,Cz=z)
datos
```

```
   Cx Cy    Cz
A   5  M FALSE
B   9  M FALSE
C   9  M FALSE
D   9  F FALSE
E  10  M FALSE
F   9  M  TRUE
G   3  M  TRUE
H   6  F  TRUE
I   9  M  TRUE
J   8  M FALSE
```



Nombres de filas II

¿Qué pasa si más de un vector tiene nombres? Veamos

```
names(y)=LETTERS[1:10]
names(x)=month.abb[1:10]
datos=data.frame(Cy=y,Cx=x,Cz=z,row.names=names(x))
datos
```

```
    Cy Cx    Cz
Jan  M  5 FALSE
Feb  M  9 FALSE
Mar  M  9 FALSE
Apr  F  9 FALSE
May  M 10 FALSE
Jun  M  9  TRUE
Jul  M  3  TRUE
Aug  F  6  TRUE
Sep  M  9  TRUE
Oct  M  8 FALSE
```



Nombres de filas IV

Si no quiero nombres de fila se lo indico de la siguiente forma

```
datos=data.frame(Cy=y,Cx=x,Cz=z,row.names=NULL)
datos
```

```
   Cy Cx    Cz
1   M  5 FALSE
2   M  9 FALSE
3   M  9 FALSE
4   F  9 FALSE
5   M 10 FALSE
6   M  9  TRUE
7   M  3  TRUE
8   F  6  TRUE
9   M  9  TRUE
10  M  8 FALSE
```



Nombres de filas, usos

Los nombres de filas se pueden usar para recuperar filas del data (indexamos el data con un vector de caracteres que contiene los nombres de las filas que quiere recuperar)

```
datos=data.frame(Cx=x,Cy=y,Cz=z)
datos[c('Jan','Mar','May'),]
```

```
    Cx Cy    Cz
Jan  5  M FALSE
Mar  9  M FALSE
May 10  M FALSE
```



Recuperación de nombres de filas

Para recuperar los nombres de filas de un data usamos la función `row.names` o `rownames`

```
# filas
row.names(datos)
```

```
 [1] "Jan" "Feb" "Mar" "Apr" "May" "Jun" "Jul" "Aug" "Sep" "Oct"
```

```
rownames(datos)
```

```
 [1] "Jan" "Feb" "Mar" "Apr" "May" "Jun" "Jul" "Aug" "Sep" "Oct"
```

```
# columnas
colnames(datos)
```

```
[1] "Cx" "Cy" "Cz"
```



Recuperar nombres de columnas

Para recuperar los dombres de las columnas usamos `colnames`, de la siguiente forma

```
# columnas
colnames(datos)
```

```
[1] "Cx" "Cy" "Cz"
```



Nombres de filas y columnas al tiempo

La función `dimnames()` regresa una lista cuya primera componente tiene el vector de nombres de fila y la segunda el vector de nombres de columnas.

```
dimnames(datos)
```

```
[[1]]
 [1] "Jan" "Feb" "Mar" "Apr" "May" "Jun" "Jul" "Aug" "Sep" "Oct"

[[2]]
[1] "Cx" "Cy" "Cz"
```



Cambio de nombre

Para cambiar los nombres de columnas procedemos de la siguiente forma

```
colnames(datos)=c('Colx','Coly','Colz')
datos
```

```
    Colx Coly  Colz
Jan    5    M FALSE
Feb    9    M FALSE
Mar    9    M FALSE
Apr    9    F FALSE
May   10    M FALSE
Jun    9    M  TRUE
Jul    3    M  TRUE
Aug    6    F  TRUE
Sep    9    M  TRUE
Oct    8    M FALSE
```



Cambiar el nombre de una sola columna

```
colnames(datos)[2]='Col2'
datos
```

```
    Colx Col2  Colz
Jan    5    M FALSE
Feb    9    M FALSE
Mar    9    M FALSE
Apr    9    F FALSE
May   10    M FALSE
Jun    9    M  TRUE
Jul    3    M  TRUE
Aug    6    F  TRUE
Sep    9    M  TRUE
Oct    8    M FALSE
```



Adición de columnas



Creación de nuevas columnas, uso de $

Podemos crear nuevas columnas en un data frame, a partir de las columnas existentes, de la siguiente forma

```
datos$Cx2=datos$Colx^2
datos
```

```
    Colx Col2  Colz Cx2
Jan    5    M FALSE  25
Feb    9    M FALSE  81
Mar    9    M FALSE  81
Apr    9    F FALSE  81
May   10    M FALSE 100
Jun    9    M  TRUE  81
Jul    3    M  TRUE   9
Aug    6    F  TRUE  36
Sep    9    M  TRUE  81
Oct    8    M FALSE  64
```



Uso de ['nombre']

Crearemos una columna que contiene la columna Col2 codificada de la siguiente forma: Si Col2 es M asignamos 1 (uno), si es F asignamos 0 (cero).

```
datos["Sex"]=ifelse(datos$Col2=="M",1,0)
datos
```

```
    Colx Col2  Colz Cx2 Sex
Jan    5    M FALSE  25   1
Feb    9    M FALSE  81   1
Mar    9    M FALSE  81   1
Apr    9    F FALSE  81   0
May   10    M FALSE 100   1
Jun    9    M  TRUE  81   1
Jul    3    M  TRUE   9   1
Aug    6    F  TRUE  36   0
Sep    9    M  TRUE  81   1
Oct    8    M FALSE  64   1
```



Borrado de columna

Para borrar una columna usamos NULL de la siguiente forma

```
datos$Cx2=NULL
datos
```

```
    Colx Col2  Colz Sex
Jan    5    M FALSE   1
Feb    9    M FALSE   1
Mar    9    M FALSE   1
Apr    9    F FALSE   0
May   10    M FALSE   1
Jun    9    M  TRUE   1
Jul    3    M  TRUE   1
Aug    6    F  TRUE   0
Sep    9    M  TRUE   1
Oct    8    M FALSE   1
```



Indexado



Indexando Data Frames

Como con los vectores y matrices, podemos indexar un data frame usando como indices

- Enteros positivos
- Enteros negativos
- Valores lógicos
- Caracteres

Esto es válido tanto para filas como para columnas



Veamos algunos ejemplos

Seleccionamos las filas con índice 1, 5, 7, 9, 10 y las columnas con índice 2 y 3

```
datos[c(1,5,7,9,10),c(2,3)]
```

```
    Col2  Colz
Jan    M FALSE
May    M FALSE
Jul    M  TRUE
Sep    M  TRUE
Oct    M FALSE
```



Indexado con números negativos

Seleccionamos las filas con índice `distintos` a 1, 5, 7, 9, 10 y las columnas con índice `distintos` a 2 y 3

```
datos[-c(1,5,7,9,10),-c(2,3)]
```

```
    Colx Sex
Feb    9   1
Mar    9   1
Apr    9   0
Jun    9   1
Aug    6   0
```



Ejemplo de indexado con caracteres

Válido cuando las filas tienen nombres

```
datos[c('Feb','Apr','Jun','Aug'),-1]
```

```
    Col2  Colz Sex
Feb    M FALSE   1
Apr    F FALSE   0
Jun    M  TRUE   1
Aug    F  TRUE   0
```



Indexación lógica

En este tipo de indexación se extraen las filas o columnas que coincidan con un valor TRUE , veamos ejemplos

```
datos[c(TRUE,FALSE,TRUE,FALSE,TRUE,FALSE,TRUE,FALSE,TRUE,FALSE), ]
```

```
    Colx Col2  Colz Sex
Jan    5    M FALSE   1
Mar    9    M FALSE   1
May   10    M FALSE   1
Jul    3    M  TRUE   1
Sep    9    M  TRUE   1
```

```
datos[!c(TRUE,FALSE,TRUE,FALSE,TRUE,FALSE,TRUE,FALSE,TRUE,FALSE), ]
```

```
    Colx Col2  Colz Sex
Feb    9    M FALSE   1
Apr    9    F FALSE   0
Jun    9    M  TRUE   1
Aug    6    F  TRUE   0
```



Ejercicio

Ejercicio: Calcular la media de `Colx` pero para aquellas filas conde `Col2` es igual a “M” y separadamente para donde `Col2` es igual a “F”

```
datosM=datos[datos$Col2=="M",]
mean(datosM$Colx)
```

```
[1] 7.75
```

Para los femeninos, es decir, donde `Col2` es igual a “F”

```
datosF=datos[datos$Col2=="F",]
mean(datosF$Colx)
```

```
[1] 7.5
```



Otra forma, usando la negación

```
datosF=datos[!datos$Col2=="M",]
mean(datosF$Colx)
```

```
[1] 7.5
```



Ejercicio

Calcular la varianza de `Colx` para aquellas filas donde `Colz` es TRUE

```
var(datos[datos$Colz,][["Colx"]])
```

```
[1] 8.25
```



Ejercicio

Calcular la varianza de `Colx` para aquellas filas donde `Colz` es FALSE

```
var(datos[!datos$Colz,][["Colx"]])
```

```
[1] 3.066667
```



Ejercicio

Calcular la media de `Colx` para equellas filas donde `Col2` es 'M' y `Colz` es FALSE

```
mean(datos[datos$Col2=='M' & !datos$Colz, ][['Colx']])
```

```
[1] 8.2
```



Ejercicio

Cuántos hombres, es decir Col2=='M' tienen un valor de `Colx` por encima de la media de `Colx`

```
nrow(datos[datos$Colx>mean(datos$Colx) & datos$Col2=="M" ,]  )
```

```
[1] 6
```



otra forma

```
sum(datos$Colx>mean(datos$Colx) & datos$Col2=="M")
```

```
[1] 6
```



otra forma

```
sum(datos[datos$Colx>mean(datos$Colx),][['Col2']]=="M"  )
```

```
[1] 6
```

